

Московский Государственный Университет имени М. В. Ломоносова
Факультет Вычислительной Математики и Кибернетики
Кафедра Суперкомпьютеров и Квантовой Информатики

Практикум CUDA

Отчет №2

Basic Image Convolution on NVIDIA GPUs using CUDA(with performance improvements)

Работу выполнил
Кислов Евгений

Москва 2021

Постановка задачи

Для выполнения второго задания необходимо реализовать следующие оптимизации разработанной на первом этапе программы:

Оптимизации для обработки больших и малых изображений:

1. Развертка массива, где хранится изображение из массива структур в структуру массивов для улучшения шаблона доступа к глобальной памяти (Pixel * -> 3 массива
3. unsigned char* для хранения 3 компонент изображения);
4. Последовательный доступ к памяти от нитей варпа к массиву с изображением;
5. Использование разделяемой (shared) памяти для применения фильтра (по аналогии со stencil);
6. Использование 3х нитей для обработки r/g/b компонент;
7. Различные походы к передаче фильтра в матрицу (full unroll, константная память);
8. Развертка циклов, применяющих фильтров внутри каждой нити;
9. Подбор оптимальных значений размера CUDA блока;
10. Минимизация числа простаивающих нитей;

Дополнительные оптимизации для обработки набора из маленьких изображений:

1. Выделение памяти (cudaMalloc) под обрабатываемые изображения 1 раз (а не каждый раз для каждого изображения заново);
2. Обработка нескольких изображений за раз одним ядром или обработка нескольких изображений в конкурентном режиме при помощи CUDA-потокв;
3. Одновременные копирования DtoH, HtoD и запуск ядер;
4. Параллельная работа с файлами обработка изображений на GPU для групп из N - изображений: загружаем группу из N изображений с диска, пока их обрабатываем - грузим следующую. Сохранение на диск можно отключить (ifdef __NEED_TO_SAVE__).


Результат

Из списка общих оптимизаций были выполнены все пункты, из списка оптимизаций для маленький изображений было выполнены пункты 2-4.

Ниже будут приведены замеры времени и графики для наиболее важных оптимизаций:

Вид оптимизации	Время вычисления на большой картинке(ms)	Время вычисления на маленьких картинках(ms)	Ускорение(в среднем по двум случаям)
Начальная версия	0.602816	0.26464	-

Развертка массивов	0.54472	0.216864	1.1
Разбиение массива пикселей на три	0.541745	0.213487	1.1
Shared memory	0.498944	0.19292	1.22



Графики оптимизаций:

После оптимизаций маленьких картинок время пересылки уменьшилось с 4.83 мс до 3.64 мс, дав ускорение в 1.32 раза.

Данные профилировщика nvprof в начальной версии:

Для больших

```
==118650== Profiling result:
Start Duration Grid Size Block Size Regs* SSMem* DSMem* Size Throughput SrcMemType DstMemType Device Context Stream Name
484.83ms 3.2807ms - - - - 14.832MB 4.5250GB/s Pageable Device Tesla P100-SXM2 1 7 [CUDA memcpy HtoD]
487.49ms 890ns - - - - 36B 38.317MB/s Pageable Device Tesla P100-SXM2 1 7 [CUDA memcpy HtoD]
487.73ms 550.79us (90 57 1) (32 32 1) 40 0B 0B - - Tesla P100-SXM2 1 7 apply_kernel_device(unsigned char*, unsigned char*, int, int, float*, char) [221]
488.30ms 2.8804ms - - - - 14.832MB 5.0285GB/s Device Pageable Tesla P100-SXM2 1 7 [CUDA memcpy DtoH]

Regs: Number of registers used per CUDA thread. This number includes registers used internally by the CUDA driver and/or tools and can be more than what the compiler shows.
SSMem: Static shared memory allocated per CUDA block.
DSMem: Dynamic shared memory allocated per CUDA block.
SrcMemType: The type of source memory accessed by memory operation/copy.
DstMemType: The type of destination memory accessed by memory operation/copy.
```

```

==116070== Profiling result:
      Type      Time      Time      Calls      Avg      Min      Max      Name
GPU activities:  47.66%  3.1790ms      2  1.5895ms  896ns  3.1781ms  [CUDA memcpy HtoD]
                  44.08%  2.9401ms      1  2.9401ms  2.9401ms  2.9401ms  [CUDA memcpy DtoH]
                  8.26%  550.86us      1  550.86us  550.86us  550.86us  apply_kernel_device(unsigned char*, unsigned char*, int, in
t, float*, char)
API calls:       94.06%  190.50ms      4  47.626ms  1.2870us  190.50ms  cudaEventCreate
                  3.31%  6.7104ms      3  2.2368ms  14.726us  3.4149ms  cudaMemcopy
                  1.03%  2.0892ms      2  1.0446ms  1.0393ms  1.0500ms  cuDeviceTotalMem
                  0.47%  949.17us     188  5.0480us  247ns  192.77us  cuDeviceGetAttribute
                  0.28%  561.87us      4  140.47us  4.1210us  547.62us  cudaEventSynchronize
                  0.27%  552.57us      3  184.19us  156.97us  223.64us  cudaMalloc
                  0.26%  517.44us      3  172.48us  126.16us  248.28us  cudaFree
                  0.23%  474.06us      1  474.06us  474.06us  474.06us  cudaGetDeviceProperties
                  0.04%  79.603us      2  39.801us  38.441us  41.162us  cuDeviceGetName
                  0.02%  44.633us      1  44.633us  44.633us  44.633us  cudaLaunch
                  0.02%  32.840us      4  8.2100us  5.0920us  15.635us  cudaEventRecord
                  0.00%  9.8810us      2  4.9400us  4.8670us  5.0140us  cudaEventElapsedTime
                  0.00%  2.6830us      3  894ns  385ns  1.8980us  cuDeviceGetCount
                  0.00%  1.9580us      6  326ns  258ns  444ns  cudaSetupArgument
                  0.00%  1.5800us      4  395ns  246ns  652ns  cuDeviceGet
                  0.00%  1.3930us      1  1.3930us  1.3930us  1.3930us  cudaConfigureCall

```

Для маленьких

Start	Duration	Grid Size	Block Size	Regs*	SSMem*	DSMem*	Size	Throughput	SrcMemType	DstMemType	Device	Context	Stream	Name
276.48ms	11.840us	-	-	-	-	-	263.67KB	22.777GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
276.58ms	544ns	-	-	-	-	-	368	63.111MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
276.57ms	11.552us	(18 18 1)	(32 32 1)	40	08	08	-	-	-	-	Tesla P100-SXM2	1	7	apply_kernel_device(assigned char)
, unsigned char*, int, int, float*, char [221]														
276.60ms	12.081us	-	-	-	-	-	263.67KB	20.953GB/s	Device	Pageable	Tesla P100-SXM2	1	7	[CUDA memcpy DtoH]
276.67ms	10.443us	-	-	-	-	-	263.67KB	24.146GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
389.69ms	512ns	-	-	-	-	-	368	67.059MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
389.73ms	11.105us	(18 18 1)	(32 32 1)	40	08	08	-	-	-	-	Tesla P100-SXM2	1	7	apply_kernel_device(assigned char)
, unsigned char*, int, int, float*, char [252]														
389.76ms	12.803us	-	-	-	-	-	263.67KB	20.953GB/s	Device	Pageable	Tesla P100-SXM2	1	7	[CUDA memcpy DtoH]
389.78ms	10.369us	-	-	-	-	-	263.67KB	24.251GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
389.67ms	480ns	-	-	-	-	-	368	71.526MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
389.72ms	10.816us	(18 18 1)	(32 32 1)	40	08	08	-	-	-	-	Tesla P100-SXM2	1	7	apply_kernel_device(assigned char)
, unsigned char*, int, int, float*, char [283]														
389.74ms	11.969us	-	-	-	-	-	263.67KB	21.009GB/s	Device	Pageable	Tesla P100-SXM2	1	7	[CUDA memcpy DtoH]
389.79ms	10.176us	-	-	-	-	-	263.67KB	24.711GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
388.81ms	512ns	-	-	-	-	-	368	67.059MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
389.86ms	10.743us	(18 18 1)	(32 32 1)	40	08	08	-	-	-	-	Tesla P100-SXM2	1	7	apply_kernel_device(assigned char)
, unsigned char*, int, int, float*, char [314]														
388.88ms	12.353us	-	-	-	-	-	263.67KB	20.356GB/s	Device	Pageable	Tesla P100-SXM2	1	7	[CUDA memcpy DtoH]
426.11ms	9.306us	-	-	-	-	-	263.67KB	25.106GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
426.13ms	512ns	-	-	-	-	-	368	67.059MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
426.17ms	10.785us	(18 18 1)	(32 32 1)	40	08	08	-	-	-	-	Tesla P100-SXM2	1	7	apply_kernel_device(assigned char)
, unsigned char*, int, int, float*, char [345]														
426.20ms	12.833us	-	-	-	-	-	263.67KB	20.897GB/s	Device	Pageable	Tesla P100-SXM2	1	7	[CUDA memcpy DtoH]
462.69ms	10.048us	-	-	-	-	-	263.67KB	25.026GB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
462.71ms	512ns	-	-	-	-	-	368	67.059MB/s	Pageable	Device	Tesla P100-SXM2	1	7	[CUDA memcpy HtoD]
462.75ms	10.817us	(18 18 1												

```

==117457== Profiling result:
      Type      Time      Calls      Avg      Min      Max      Name
GPU activities: 35.43% 84.197us    7 12.028us 12.000us 12.065us [CUDA memcpy DtoH]
               32.38% 76.932us    7 10.990us 10.785us 11.616us apply_kernel_device(unsigned char*, unsigned char*, int, in
t, float*, char)
               32.19% 76.487us   14 5.4630us 512ns 11.809us [CUDA memcpy HtoD]
               95.15% 139.21ms   28 4.9718ms 1.2970us 139.15ms cudaEventCreate
               1.43% 2.0897ms    2 1.0449ms 1.0387ms 1.0511ms cuDeviceTotalMem
               0.87% 1.2776ms   21 60.839us 7.4290us 172.59us cudaMalloc
               0.73% 1.0720ms   21 51.046us 8.5000us 147.62us cudaFree
               0.69% 1.0145ms  188 5.3960us 241ns 215.63us cuDeviceGetAttribute
               0.41% 601.36us   21 28.636us 9.1310us 77.857us cudaMemcpy
               0.32% 469.19us   1 469.19us 469.19us 469.19us cudaGetDeviceProperties
               0.11% 161.31us   28 5.7610us 3.5550us 11.061us cudaEventSynchronize
               0.09% 132.79us   7 18.969us 14.802us 38.088us cudaLaunch
               0.08% 114.29us   28 4.0810us 3.3830us 10.508us cudaEventRecord
               0.06% 85.042us   2 42.521us 38.385us 46.657us cuDeviceGetName
               0.04% 64.138us   14 4.5810us 4.2270us 5.5800us cudaEventElapsedTime
               0.01% 12.617us   42 300ns 242ns 1.0160us cudaSetupArgument
               0.00% 3.4250us    7 489ns 344ns 920ns cudaConfigureCall
               0.00% 2.6510us    3 883ns 367ns 1.8700us cuDeviceGetCount
               0.00% 1.5290us    4 382ns 257ns 571ns cuDeviceGet

```

Данные профилировщика nvprof в оптимизированной версии:

Для больших

```

--186956== Profiling application: ./a.out emboss -b input_img/big/big_1.png output_img/big/big_1.png
--186956== Profiling result:
   Start   Duration      Grid Size      Block Size      Regs#    SSMem#    DSMem#    SrcMemType    DstMemType    Device    Context    Stream    Name
489.83s    928ns              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy HtoD]
490.28s    9742us              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy HtoD]
490.48s    856.59us              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy HtoD]
491.67s    967.76us              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy HtoD]
492.71s    480.52us    (98 57 1)    (32 32 1)    36 3.3867KB    0B      -      -      -      -      Tesla P100-SXM2  1      15 apply_kernel_device_3x3(unsigned c
493.23s    1.227ms              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy DtoH]
494.98s    799.63us              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy DtoH]
496.21s    815.86us              -              -              -              -              -      Pageable      Pageable      Tesla P100-SXM2  1      15 [CUDA memcopy DtoH]

Regs: Number of registers used per CUDA thread. This number includes registers used internally by the CUDA driver and/or tools and can be more than what the compiler shows.
SSMem: Static shared memory allocated per CUDA block.
DSMem: Dynamic shared memory allocated per CUDA block.
SrcMemType: The type of source memory accessed by memory operation/copy
DstMemType: The type of destination memory accessed by memory operation/copy

```

```

==104348== Profiling result:
   Type Time(%)   Time     Calls      Avg      Min      Max   Name
GPU activities:  46.25% 2.8975ms    4 724.37us 1.0880us 974.26us [CUDA memcopy HtoD]
                 46.07% 2.8865ms    3 962.16us 807.98us 1.2029ms [CUDA memcopy DtoH]
                 7.68% 480.91us    1 480.91us 480.91us 480.91us apply_kernel_device_3x3(unsigned char*, unsigned char*, unsigned char*, unsigned char*,
unsigned char*, unsigned char*, int, int, float*)
API calls:       90.71% 138.88ms    1 138.88ms 138.88ms 138.88ms cudaStreamCreate
                 5.14% 7.872ms    7 1.1247ms 20.937us 1.8136ms cudaMemcopyAsync
                 1.37% 2.0920ms    2 1.0460ms 1.0415ms 1.0505ms cuDeviceTotalMem
                 0.67% 1.0250ms    7 146.43us 128.40us 232.57us cudaFree
                 0.66% 1.0143ms    7 145.18us 142.41us 156.83us cudaMalloc
                 0.66% 1.0121ms   188 5.3830us 250ns 213.70us cuDeviceGetAttribute
                 0.33% 503.71us    4 125.93us 4.7830us 479.31us cudaEventSynchronize
                 0.30% 465.27us    1 465.27us 465.27us 465.27us cudaGetDeviceProperties
                 0.05% 79.649us    2 39.824us 38.436us 41.213us cuDeviceGetName
                 0.03% 51.204us    1 51.204us 51.204us 51.204us cudaLaunch
                 0.02% 34.601us    4 8.6580us 5.2580us 11.036us cudaEventRecord
                 0.02% 25.969us    1 25.969us 25.969us 25.969us cudaDeviceSynchronize
                 0.01% 14.994us    1 14.994us 14.994us 14.994us cudaStreamDestroy
                 0.01% 9.9830us    2 4.9910us 4.9760us 5.0070us cudaEventElapsedTime
                 0.01% 8.1720us    4 2.0430us 1.3120us 3.9460us cudaEventCreate
                 0.00% 2.6970us    9 299ns 242ns 400ns cudaSetupArgument
                 0.00% 2.6070us    3 869ns 342ns 1.6230us cuDeviceGetCount
                 0.00% 1.4740us    4 368ns 272ns 472ns cuDeviceGet
                 0.00% 1.4550us    1 1.4550us 1.4550us 1.4550us cudaConfigureCall

```

Для маленьких

```

==108807== Profiling result:
   Start Duration   Grid Size   Block Size   Regs*   SMMem*   DSMem*   Size   Throughput   SrcMemType   DstMemType   Device   Context   Stream   Name
271.98ms  929ns      -           -           -         -         -       36B  36.956MB/s   Pageable     Device       Tesla P100-SXM2  1       15 [CUDA memcopy HtoD]
271.92ms  4.2880us    -           -           -         -         -       87.891KB 19.5470B/s Pageable     Device       Tesla P100-SXM2  1       15 [CUDA memcopy HtoD]
271.93ms  4.8330us    -           -           -         -         -       87.891KB 20.7830B/s Pageable     Device       Tesla P100-SXM2  1       15 [CUDA memcopy HtoD]
271.95ms  4.1610us    -           -           -         -         -       87.891KB 20.1440B/s Pageable     Device       Tesla P100-SXM2  1       15 [CUDA memcopy HtoD]
272.01ms 11.185us    (10 10 1)   (32 32 1)   36 3.3867KB 0B      -       -         -         -         -         Tesla P100-SXM2  1       15 apply_kernel_device_3x3(unsigned c
harr*, unsigned char*, unsigned char*, unsigned char*, unsigned char*, int, int, float*) [231]
272.05ms 3.7760us    -           -           -         -         -       87.891KB 22.1980B/s Device       Pageable     Tesla P100-SXM2  1       15 [CUDA memcopy DtoH]
272.08ms 3.7220us    -           -           -         -         -       87.891KB 22.5810B/s Device       Pageable     Tesla P100-SXM2  1       15 [CUDA memcopy DtoH]
272.11ms 3.6160us    -           -           -         -         -       87.891KB 23.1800B/s Device       Pageable     Tesla P100-SXM2  1       15 [CUDA memcopy DtoH]
311.73ms 704ns       -           -           -         -         -       36B 48.767MB/s Pageable     Device       Tesla P100-SXM2  1       16 [CUDA memcopy HtoD]
311.74ms 3.8730us    -           -           -         -         -       87.891KB 21.6420B/s Pageable     Device       Tesla P100-SXM2  1       16 [CUDA memcopy HtoD]
311.75ms 3.6800us    -           -           -         -         -       87.891KB 22.7770B/s Pageable     Device       Tesla P100-SXM2  1       16 [CUDA memcopy HtoD]
311.77ms 4.0000us    -           -           -         -         -       87.891KB 20.9550B/s Pageable     Device       Tesla P100-SXM2  1       16 [CUDA memcopy HtoD]
311.80ms 10.593us    (10 10 1)   (32 32 1)   36 3.3867KB 0B      -       -         -         -         -         Tesla P100-SXM2  1       16 apply_kernel_device_3x3(unsigned c
harr*, unsigned char*, unsigned char*, unsigned char*, unsigned char*, int, int, float*) [200]
311.84ms 3.7120us    -           -           -         -         -       87.891KB 22.5810B/s Device       Pageable     Tesla P100-SXM2  1       16 [CUDA memcopy DtoH]
311.86ms 3.6800us    -           -           -         -         -       87.891KB 22.7770B/s Device       Pageable     Tesla P100-SXM2  1       16 [CUDA memcopy DtoH]
311.88ms 3.6170us    -           -           -         -         -       87.891KB 23.1740B/s Device       Pageable     Tesla P100-SXM2  1       16 [CUDA memcopy DtoH]
350.96ms 704ns       -           -           -         -         -       36B 48.767MB/s Pageable     Device       Tesla P100-SXM2  1       17 [CUDA memcopy HtoD]
350.98ms 3.8080us    -           -           -         -         -       87.891KB 22.0110B/s Pageable     Device       Tesla P100-SXM2  1       17 [CUDA memcopy HtoD]
350.99ms 3.8720us    -           -           -         -         -       87.891KB 21.6470B/s Pageable     Device       Tesla P100-SXM2  1       17 [CUDA memcopy HtoD]
351.00ms 3.8080us    -           -           -         -         -       87.891KB 22.0110B/s Pageable     Device       Tesla P100-SXM2  1       17 [CUDA memcopy HtoD]
351.04ms 10.369us    (10 10 1)   (32 32 1)   36 3.3867KB 0B      -       -         -         -         -         Tesla P100-SXM2  1       17 apply_kernel_device_3x3(unsigned c
harr*, unsigned char*, unsigned char*, unsigned char*, unsigned char*, int, int, float*) [329]
351.07ms 3.7120us    -           -           -         -         -       87.891KB 22.5810B/s Device       Pageable     Tesla P100-SXM2  1       17 [CUDA memcopy DtoH]
351.09ms 3.6800us    -           -           -         -         -       87.891KB 22.7770B/s Device       Pageable     Tesla P100-SXM2  1       17 [CUDA memcopy DtoH]
351.11ms 3.6910us    -           -           -         -         -       87.891KB 22.7710B/s Device       Pageable     Tesla P100-SXM2  1       17 [CUDA memcopy DtoH]
391.51ms 704ns       -           -           -         -         -       36B 48.767MB/s Pageable     Device       Tesla P100-SXM2  1       18 [CUDA memcopy HtoD]
391.52ms 3.7760us    -           -           -         -         -       87.891KB 22.1980B/s Pageable     Device       Tesla P100-SXM2  1       18 [CUDA memcopy HtoD]

```

```

==102440== Profiling application: ./a.out emboss --s input_img_small output_img_small
==102448== Profiling result:
   Type Time(%)   Time     Calls      Avg      Min      Max   Name
GPU activities:  37.13% 89.028us   28 3.1790us 704ns 5.2480us [CUDA memcopy HtoD]
                 32.17% 77.121us   21 3.6720us 3.6160us 3.7440us [CUDA memcopy DtoH]
                 30.70% 73.605us    7 10.515us 10.369us 10.944us apply_kernel_device_3x3(unsigned char*, unsigned char*, unsigned char*, unsigned char*,
unsigned char*, unsigned char*, int, int, float*)
API calls:       94.39% 139.14ms    7 19.877ms 9.2850us 139.07ms cudaStreamCreate
                 1.42% 2.0861ms    2 1.0431ms 1.0390ms 1.0471ms cuDeviceTotalMem
                 1.07% 1.5806ms   49 32.257us 6.2110us 214.44us cudaMalloc
                 0.94% 1.3847ms   49 28.259us 7.8990us 148.96us cudaFree
                 0.66% 970.18us   188 5.1680us 246ns 201.95us cuDeviceGetAttribute
                 0.65% 965.34us   49 19.700us 10.254us 49.531us cudaMemcopyAsync
                 0.51% 460.25us    1 460.25us 460.25us 460.25us cudaGetDeviceProperties
                 0.12% 172.57us    7 24.652us 18.125us 40.448us cudalaunch
                 0.12% 171.38us   28 6.1200us 3.6530us 11.004us cudaEventSynchronize
                 0.10% 141.91us   28 5.0680us 3.9080us 10.922us cudaEventRecord
                 0.06% 91.496us    2 45.748us 44.773us 46.723us cuDeviceGetName
                 0.05% 68.107us    7 9.7290us 9.0130us 11.787us cudaStreamDestroy
                 0.05% 67.520us   14 4.8220us 4.5020us 5.2050us cudaEventElapsedTime
                 0.03% 49.272us   28 1.7590us 1.2770us 4.3440us cudaEventCreate
                 0.03% 41.251us    7 5.8930us 5.6690us 6.5060us cudaDeviceSynchronize
                 0.01% 17.844us   63 283ns 246ns 608ns cudaSetupArgument
                 0.00% 3.9480us    7 564ns 367ns 908ns cudaConfigureCall
                 0.00% 2.7410us    3 913ns 356ns 1.9690us cuDeviceGetCount
                 0.00% 1.6550us    4 413ns 268ns 629ns cuDeviceGet

```

Выводы

- Развертка циклов и использование shared-памяти помогает значительно(вплоть до 20%) ускорить вычисления на GPU.
- В случае, когда в программе требуется вызывать несколько раз обработку на GPU, можно достичь ускорение(вплоть до 30%) при помощи CUDA-потокков.
- Транспорт по-прежнему является узким местом данной технологии.